

# Theoretische Informatik HS24

---

Nicolas Wehrli

Übungsstunde 02

2. Oktober 2024

ETH Zürich

*nwehrli@ethz.ch*

- ① Letzte Woche & Feedback zur Serie
- ② Kolmogorov Komplexität - Theorie
- ③ How To Kolmogorov

## Letzte Woche & Feedback zur Serie

---

- I. Grundsätzlich gut.
- II. Bei manchen die Länge reduzieren und konkreter argumentieren.
- III. Bei anderen hat Argumentation gefehlt. Steht in der Korrektur.
- IV. Bei Aufgabe 3:  $k$  und  $l$  beliebig. Alle Antworten müssen begründet werden.

# Kolmogorov Komplexität - Theorie

---

# Vorläufige Definition des Begriffs Algorithmus

Mathematische Definition folgt in Kapitel 4 (Turingmaschinen).

Vorerst betrachten wir Programme, die **für jede zulässige Eingabe halten und eine Ausgabe liefern**, als Algorithmen.

Wir betrachten ein Programm (Algorithmus)  $A$  als Abbildung  $A : \Sigma_1^* \rightarrow \Sigma_2^*$  für beliebige Alphabete  $\Sigma_1$  und  $\Sigma_2$ . Dies bedeutet, dass

- (i) die Eingaben als Wörter über  $\Sigma_1$  kodiert sind,
- (ii) die Ausgaben als Wörter über  $\Sigma_2$  kodiert sind und
- (iii)  $A$  für jede Eingabe eine eindeutige Ausgabe bestimmt.

$A$  und  $B$  äquivalent  $\iff$  Eingabealphabet  $\Sigma$  gleich,  $A(x) = B(x), \forall x \in \Sigma^*$

Ie. diese Notion von "Äquivalenz" bezieht sich nur auf die Ein und Ausgabe.

# Algorithmen generieren Wörter

Sei  $\Sigma$  ein Alphabet und  $x \in \Sigma^*$ . Wir sagen, dass ein Algorithmus  $A$  das Wort  $x$  **generiert**, falls  $A$  für die Eingabe  $\lambda$  die Ausgabe  $x$  liefert.

Beispiel:

```
 $A_n$ :      begin
                for  $i = 1$  to  $n$ ;
                    write (01);
                end
```

$A_n$  generiert  $(01)^n$ .

Sei  $\Sigma$  ein Alphabet und sei  $L \subseteq \Sigma^*$ .  $A$  ist ein **Aufzählungsalgorithmus** für  $L$ , falls  $A$  für jede Eingabe  $n \in \mathbb{N} \setminus \{0\}$  die Wortfolge  $x_1, \dots, x_n$  ausgibt, wobei  $x_1, \dots, x_n$  die kanonisch  $n$  ersten Wörter in  $L$  sind.



Das **Entscheidungsproblem**  $(\Sigma, L)$  für ein gegebenes Alphabet  $\Sigma$  und eine gegebene Sprache  $L \subseteq \Sigma^*$  ist, für jedes  $x \in \Sigma^*$  zu entscheiden, ob

$$x \in L \text{ oder } x \notin L.$$

Ein Algorithmus  $A$  **löst** das Entscheidungsproblem  $(\Sigma, L)$ , falls für alle  $x \in \Sigma^*$  gilt:

$$A(x) = \begin{cases} 1, & \text{falls } x \in L, \\ 0, & \text{falls } x \notin L. \end{cases}$$

Wir sagen auch, dass  $A$  die Sprache  $L$  erkennt.

## Aufgabe 2.21 - machen wir am Ende

Wenn für eine Sprache  $L$  ein Algorithmus existiert, der  $L$  erkennt, sagen wir, dass  $L$  **rekursiv** ist.

$$L \in \mathcal{L}_R$$

### Aufgabe 2.21

Beweisen Sie, dass eine Sprache  $L$  genau dann rekursiv ist, wenn ein Aufzählungsalgorithmus für  $L$  existiert.

Wir beschränken uns auf  $\Sigma_{\text{bool}}$

## Kolmogorov-Komplexität

Für jedes Wort  $x \in (\Sigma_{\text{bool}})^*$  ist die **Kolmogorov-Komplexität**  $K(x)$  **des Wortes**  $x$  das Minimum der binären Längen, der Pascal-Programme, die  $x$  generieren.

$K(x)$  ist die kürzestmögliche Länge einer Beschreibung von  $x$ .

Die einfachste (und triviale) Beschreibung von  $x$ , ist wenn man  $x$  direkt angibt.

$x$  kann aber eine Struktur oder Regelmässigkeit haben, die eine Komprimierung erlaubt.

Welche Programmiersprache gewählt wird verändert die Kolmogorov-Komplexität nur um eine Konstante. (Satz 2.1)

## Beispiel

Sei  $w = 0101010101010101010101010101010101010101$ . Die Länge von  $w$  ist  $|w| = 40$  und die triviale Beschreibungslänge wäre wie gegeben 40.

Aber durch die Regelmässigkeit von einer 20-fachen Wiederholung der Sequenz 01, können  $w$  auch durch  $(01)^{20}$  beschreiben. Hierbei ist die Beschreibungslänge ein wenig mehr als 4 Zeichen.

Es existiert eine Konstante  $d$ , so dass für jedes  $x \in (\Sigma_{\text{bool}})^*$

$$K(x) \leq |x| + d$$

Die **Kolmogorov-Komplexität** einer natürlichen Zahl  $n$  ist  $K(n) = K(\text{Bin}(n))$ .

## Lemma 2.5 - Nichtkomprimierbar

Für jede Zahl  $n \in \mathbb{N} \setminus \{0\}$  existiert ein Wort  $w_n \in (\Sigma_{\text{bool}})^n$ , so dass

$$K(w_n) \geq |w_n| = n$$

## Lemma 2.5 - Beweis

Es gibt  $2^n$  Wörter  $x_1, \dots, x_{2^n}$  über  $\Sigma_{bool}$  der Länge  $n$ . Wir bezeichnen  $C(x_i)$  als den Bitstring des kürzesten Programms, der  $x_i$  generieren kann. Es ist klar, dass für  $i \neq j : C(x_i) \neq C(x_j)$ .

Die Anzahl der nichtleeren Bitstrings, i.e. der Wörter der Länge  $< n$  über  $\Sigma_{bool}$  ist:

$$\sum_{i=1}^{n-1} 2^i = 2^n - 2 < 2^n$$

Also muss es unter den Wörtern  $x_1, \dots, x_{2^n}$  mindestens ein Wort  $x_k$  mit  $K(x_k) \geq n$  geben.



## Satz 2.1 - Programmiersprachen

Für jedes Wort  $x \in (\Sigma_{\text{bool}})^*$  und jede Programmiersprache  $A$  sei  $K_A(x)$  die Kolmogorov-Komplexität von  $x$  bezüglich der Programmiersprache  $A$ .

Seien  $A$  und  $B$  Programmiersprachen. Es existiert eine Konstante  $c_{A,B}$ , die nur von  $A$  und  $B$  abhängt, so dass

$$|K_A(x) - K_B(x)| \leq c_{A,B}$$

für alle  $x \in (\Sigma_{\text{bool}})^*$ .



Ein Wort  $x \in (\Sigma_{\text{bool}})^*$  heisst **zufällig**, falls  $K(x) \geq |x|$ .

Eine Zahl  $n$  heisst **zufällig**, falls  $K(n) = K(\text{Bin}(n)) \geq \lceil \log_2(n+1) \rceil - 1$ .

Jede Binär-Darstellung beginnt immer mit einer 1, deshalb können wir die Länge der Binär-Darstellung um 1 verkürzen.

Zufälligkeit hier bedeutet, dass ein Wort völlig unstrukturiert ist und sich nicht komprimieren lässt. Es hat nichts mit Wahrscheinlichkeit zu tun.

## Satz 2.2

Sei  $L$  eine Sprache über  $\Sigma_{\text{bool}}$ . Sei für jedes  $n \in \mathbb{N} \setminus \{0\}$ ,  $z_n$  das  $n$ -te Wort in  $L$  bezüglich der kanonischen Ordnung. Wenn ein Programm  $A_L$  existiert, das das Entscheidungsproblem  $(\Sigma_{\text{bool}}, L)$  löst, dann gilt für alle  $n \in \mathbb{N} \setminus \{0\}$ , dass

$$K(z_n) \leq \lceil \log_2(n+1) \rceil + c$$

wobei  $c$  eine von  $n$  unabhängige Konstante ist.

## Satz 2.2 - Beweisidee

Wir können aus  $A_L$ , ein Programm entwerfen, dass das kanonisch  $n$ -te Wort generiert, indem wir in der kanonischen Reihenfolge alle Wörter  $x \in (\Sigma_{bool})^*$  durchgehen und mit  $A_L$  entscheiden, ob  $x \in L$ . Dann können wir einen Counter  $c$  haben und den Prozess abbrechen, wenn der Counter  $c = n$  wird und dann dieses Wort ausgeben.

Wir sehen, dass dieses Programm ausser der Eingabe  $n$  immer gleich ist. Sei die Länge dieses Programms  $c$ , dann können wir für das  $n$ -te Wort der Sprache  $L$ ,  $z_n$ , die Kolmogorov-Komplexität auf  $n$  reduzieren, bzw:

$$K(z_n) \leq \lceil \log_2(n+1) \rceil + c$$



# Primzahlsatz

Für jede positive ganz Zahl  $n$  sei  $\text{Prim}(n)$  die Anzahl der Primzahlen kleiner gleich  $n$ .

$$\lim_{n \rightarrow \infty} \frac{\text{Prim}(n)}{n / \ln n} = 1$$

Nützliche Ungleichung

$$\ln n - \frac{3}{2} < \frac{n}{\text{Prim}(n)} < \ln n - \frac{1}{2}$$

für alle  $n \geq 67$ .

## Lemma 2.6 - schwache Version des Primzahlsatzes

Sei  $n_1, n_2, n_3, \dots$  eine steigende unendliche Folge natürlicher Zahlen mit  $K(n_i) \geq \lceil \log_2 n_i \rceil / 2$ . Für jedes  $i \in \mathbb{N} \setminus \{0\}$  sei  $q_i$  die grösste Primzahl, die die Zahl  $n_i$  teilt. Dann ist die Menge  $Q = \{q_i \mid i \in \mathbb{N} \setminus \{0\}\}$  unendlich.

**Beweis:** Wir beweisen diese Aussage per Widerspruch:

Nehmen wir zum Widerspruch an, dass die Menge  $Q = \{q_i \mid i \in \mathbb{N} \setminus \{0\}\}$  sei endlich.

Sei  $p_m$  die grösste Primzahl in  $Q$ . Dann können wir jede Zahl  $n_i$  eindeutig als

$$n_i = p_1^{r_{i,1}} \cdot p_2^{r_{i,2}} \cdot \dots \cdot p_m^{r_{i,m}}$$

für irgendwelche  $r_{i,1}, r_{i,2}, \dots, r_{i,m} \in \mathbb{N}$  darstellen.

Bemerke das die  $p_i$  ausser  $p_m$  nicht notwendigerweise in  $Q$  sein müssen, wir verwenden nur den Fakt, dass es endlich viele davon hat.

## Lemma 2.6 - Beweis continued

Sei  $c$  die binäre Länge eines Programms, das diese  $r_{i,j}$  als Eingaben nimmt und  $n_i$  erzeugt (A ist für alle  $i \in \mathbb{N}$  bis auf die Eingaben  $r_{i,1}, \dots, r_{i,m}$  gleich).

Dann gilt:

$$K(n_i) \leq c + 8 \cdot (\lceil \log_2(r_{i,1} + 1) \rceil + \lceil \log_2(r_{i,2} + 1) \rceil + \dots + \lceil \log_2(r_{i,m} + 1) \rceil)$$

Die multiplikative Konstante 8 kommt daher, dass wir für die Zahlen  $r_{i,1}, r_{i,2}, \dots, r_{i,m}$  dieselbe Kodierung, wie für den Rest des Programmes verwenden (z.B. ASCII-Kodierung), damit ihre Darstellungen eindeutig voneinander getrennt werden können. Weil  $r_{i,j} \leq \log_2 n_i, \forall j \in \{1, \dots, m\}$  erhalten wir

$$K(n_i) \leq c + 8m \cdot \lceil \log_2(\log_2 n_i + 1) \rceil, \forall i \in \mathbb{N} \setminus \{0\}$$

## Lemma 2.6 - Beweis continued 2

Weil  $m$  und  $c$  Konstanten unabhängig von  $i$  sind, kann

$$\lceil \log_2 n_i \rceil / 2 \leq K(n_i) \leq c + 8m \cdot \lceil \log_2(\log_2 n_i + 1) \rceil$$

$$\lceil \log_2 n_i \rceil / 2 \leq c + 8m \cdot \lceil \log_2(\log_2 n_i + 1) \rceil$$

nur für endlich viele  $i \in \mathbb{N} \setminus \{0\}$  gelten.

Dies ist ein Widerspruch!

Folglich ist die Menge  $Q$  unendlich.



# How To Kolmogorov

---



Sei  $w_n = (010)^{3^{2n^3}} \in \{0, 1\}^*$  für alle  $n \in \mathbb{N} \setminus \{0\}$ . Gib eine möglichst gute obere Schranke für die Kolmogorov-Komplexität von  $w_n$  an, gemessen in der Länge von  $w_n$ .

# Aufgabentyp 1

Wir zeigen ein Programm, dass  $n$  als Eingabe nimmt und  $w_n$  druckt:

```
Wn :      begin
                M := n;
                M := 2 × M × M × M;
                J := 1;
                for I = 1 to M
                    J := J × 3;
                for I = 1 to J;
                    write(010);
            end
```

# Aufgabentyp 1

Der einzige variable Teil dieses Algorithmus ist  $n$ . Der restliche Code ist von konstanter Länge. Die binäre Länge dieses Programms kann von oben durch

$$\lceil \log_2(n + 1) \rceil + c$$

beschränkt werden, für eine Konstante  $c$ .

Somit folgt

$$K(w_n) \leq \log_2(n) + c'$$

Wir berechnen die Länge von  $w_n$  als  $|w_n| = |010| \cdot 3^{2n^3} = 3^{2n^3+1}$ .

Mit ein wenig umrechnen erhalten wir

$$n = \sqrt[3]{\frac{\log_3 |w_n| - 1}{2}}$$

und die obere Schranke

$$K(w_n) \leq \log_2 \left( \sqrt[3]{\frac{\log_3 |w_n| - 1}{2}} \right) + c' \leq \log_2 \log_3 |w_n| + c''$$

## Aufgabentyp 2

Geben Sie eine unendliche Folge von Wörtern  $y_1 < y_2 < \dots$  an, so dass eine Konstante  $c \in \mathbb{N}$  existiert, so dass für alle  $i \geq 1$

$$K(y_i) \leq \log_2 \log_2 \log_3 \log_2(|y_i|) + c$$

Wir definieren die Folge  $y_1, y_2, \dots$  mit  $y_i = 0^{2^{3^{2^i}}}$  für alle  $i \in \mathbb{N}$ . Da  $|y_i| < |y_{i+1}|$  folgt die geforderte Ordnung.

Es gilt

$$i = \log_2 \log_3 \log_2 |y_i| \text{ für } i \geq 1$$

Wir zeigen ein Programm, dass  $i$  als Eingabe nimmt und  $y_i$  druckt:

```
begin
     $M := i;$ 
     $M := 2^{(3^{(2^M)})};$ 
    for  $I = 1$  to  $M$ ;
        write(0);
    end
```

Das  $^$  für die Exponentiation ist nicht Teil der originalen Pascal Syntax, aber wir verwenden es um unser Programm lesbarer zu machen.

## Aufgabentyp 2

Der einzige variable Teil dieses Programms ist das  $i$ . Der Rest hat konstante Länge. Demnach kann die Länge dieses Programms für eine Konstante  $c'$  durch

$$\lceil \log_2(i + 1) \rceil + c'$$

von oben beschränkt werden.

Somit folgt

$$\begin{aligned} K(y_i) &\leq \log_2(i) + c \\ &\leq \log_2 \log_2 \log_3 \log_2 |y_i| + c \end{aligned}$$

für eine Konstante  $c$ .

## Aufgabentyp 3

Sei  $M = \{7^i \mid i \in \mathbb{N}, i \leq 2^n - 1\}$ . Beweisen Sie, dass mindestens sieben Achtel der Zahlen in  $M$  Kolmogorov-Komplexität von mindestens  $n - 3$  haben.

Wir zeigen, dass höchstens  $\frac{1}{8}$  der Zahlen  $x \in M$  eine Kolmogorov-Komplexität  $K(x) \leq n - 4$  haben.

Nehmen wir zum Widerspruch an, dass  $M$  mehr als  $\frac{1}{8}|M|$  Zahlen  $x$  enthält, mit  $K(x) \leq n - 4$ .



Die Programme, die diese Wörter generieren, müssen paarweise verschieden sein, da die Wörter paarweise verschieden sind.

Es gibt aber höchstens

$$\sum_{k=0}^{n-4} 2^k = 2^{n-3} - 1 < \frac{1}{8}|M|$$

Bitstrings mit Länge  $\leq n - 4$ . **Widerspruch.**

Das **Entscheidungsproblem**  $(\Sigma, L)$  für ein gegebenes Alphabet  $\Sigma$  und eine gegebene Sprache  $L \subseteq \Sigma^*$  ist, für jedes  $x \in \Sigma^*$  zu entscheiden, ob

$$x \in L \text{ oder } x \notin L.$$

Ein Algorithmus  $A$  **löst** das Entscheidungsproblem  $(\Sigma, L)$ , falls für alle  $x \in \Sigma^*$  gilt:

$$A(x) = \begin{cases} 1, & \text{falls } x \in L, \\ 0, & \text{falls } x \notin L. \end{cases}$$

Wir sagen auch, dass  $A$  die Sprache  $L$  erkennt.

## Aufgabe 2.21

Wenn für eine Sprache  $L$  ein Algorithmus existiert, der  $L$  erkennt, sagen wir, dass  $L$  **rekursiv** ist.

$$L \in \mathcal{L}_R$$

### Aufgabe 2.21

Beweisen Sie, dass eine Sprache  $L$  genau dann rekursiv ist, wenn ein Aufzählungsalgorithmus für  $L$  existiert.

## Aufgabe 2.21

$L$  rekursiv ( $\implies$ ) existiert Aufzählungsalgorithmus:

Sei  $A$  ein Algorithmus, der  $L$  erkennt. Wir beschreiben nun einen Aufzählungsalgorithmus  $B$  konstruktiv.

---

**Algorithm 1**  $B(\Sigma, n)$ 

---

$i \leftarrow 0$

**while**  $i \leq n$  **do**

$w \leftarrow$  kanonisch nächstes Wort über  $\Sigma^*$

**if**  $A(w) = 1$  **then**

        print( $w$ )

$i \leftarrow i + 1$

**end if**

**end while**

---

## Aufgabe 2.21

Aufzählungsalgorithmus  $B \implies L$  rekursiv:

---

**Algorithm 2**  $A(\Sigma, w)$

---

```
 $n \leftarrow |\Sigma|^{|w|+1}$   
 $L \leftarrow B(\Sigma, n)$   
if  $w \in L$  then  
    print(1)  
else  
    print(0)  
end if
```

---

Es gibt ein kleines Problem.  $B$  könnte unendlich lange laufen, falls  $n > |L|$ . Es sollte nicht so schwierig sein,  $B$  zu modifizieren, dass es die Berechnung aufhört, falls es keine weiteren Wörter in  $L$  gibt.